

Oferta técnica EXP-1111 — versión reducida

Servicio de desarrollo e implementación de una herramienta de inteligencia artificial que asiste en tiempo real a los agentes de los canales de atención al público de AcmeInc. Expediente 1111. Presentada el 18 de noviembre de 2025.

Versión condensada de la oferta original, con terminología unificada. El cliente es **AcmeInc** (acrónimo **SGTFI**); se usan los nombres canónicos de productos, conceptos y marcos en todo el texto. Se ha unificado el nivel del ENS a **ENS Nivel Alto** (el original alterna "medio-alto" y "alto").

1. Características generales

Entelgy Consulting, S.A. (CIF A-83456202) presenta esta oferta a AcmeInc en respuesta a la licitación del expediente 1111. Entelgy es una consultora tecnológica con cerca de 2.000 empleados y más de 20 años de actividad, con presencia en España, Estados Unidos, Argentina, Brasil, Chile, Colombia, México y Perú. La duración prevista del contrato es de 20 meses.

El cliente, AcmeInc, es un organismo de la Administración Pública del ámbito del Tesoro Público. Entelgy declara conocer y aceptar todas las cláusulas del documento de licitación.

2. Entorno funcional

El servicio de atención al inversor de AcmeInc opera en un entorno multicanal. Los ciudadanos contactan por Teléfono, Email, Formulario Web, Chat Web, WhatsApp y mediante el Callback "Te Llamamos". La herramienta de IA asiste a los agentes de nivel 2, que resuelven dudas sobre operativa y compraventa de valores en el sistema SCVV (Sistema de Compraventa de Valores).

La solución procesa las consultas con independencia del canal. Cuando la entrada es de voz, el sistema transcribe la voz a texto (STT) antes de analizarla; cuando es escrita, la procesa directamente. La salida es una respuesta sugerida en texto, con opción de síntesis de voz (TTS). El agente siempre valida y comunica la respuesta final al ciudadano: la herramienta asiste en segundo plano, pero no atiende de forma autónoma ni toma decisiones con impacto sobre el ciudadano.

Las consultas abarcan normativa de productos financieros, fiscalidad, tributación de intereses, retenciones, comisiones, cálculos de rentabilidad de la deuda pública, fechas de subastas y cotizaciones en mercados secundarios. Por ello la solución se apoya en una base de conocimiento curada a partir de la documentación oficial de AcmeInc (guías y FAQs). Un Documentalista depura y cura esa documentación para garantizar la calidad de la información. El modelo se entrena además con consultas históricas reales de los dos últimos años.

Cuando una consulta deriva en una posible incidencia técnica, la herramienta guía al agente para categorizar el problema y recopilar los datos relevantes (identificación del usuario, descripción estructurada de la incidencia) y reenviarlos de forma organizada al equipo de nivel 3. La solución se integrará con el futuro CRM corporativo de AcmeInc, persistirá todas las interacciones para garantizar trazabilidad y dispondrá de una consola de gestión del corpus con reentrenamiento semiautomático.

3. Arquitectura técnica

La arquitectura es modular y se despliega sobre Microsoft Azure, gobernada por Azure AI Foundry, que unifica modelos, herramientas y control de acceso por roles (RBAC) y permite aislar proyectos por área de conocimiento. La solución se ejecuta en contenedores sobre Azure Kubernetes Service, garantizando compatibilidad con OpenShift y escalado horizontal; las imágenes versionadas y escaneadas se guardan en Azure Container Registry.

El motor generativo es Azure OpenAI, con modelos GPT-4 o GPT-5 para la generación de respuestas y text-embedding-3-large o Cohere para los embeddings. El conocimiento sigue un patrón RAG: los documentos originales (PDF, DOCX) residen en Azure Blob Storage con versionado, y Azure AI Search los indexa en español, los divide en fragmentos y los enriquece con vectores de embedding y metadatos (área, fecha, versión). Azure AI Search permite Vector Search híbrida —palabra clave y similitud semántica— que aporta Grounding al modelo y reduce las alucinaciones. Para documentos escaneados se puede usar Azure Form Recognizer. Azure Cognitive Services aporta los servicios cognitivos de base, e incluye la capacidad de Custom Question Answering para generar pares pregunta-respuesta.

Los datos estructurados —historial de preguntas, calificaciones de los agentes, usuarios y roles, configuración— se guardan en Azure SQL Database o Azure Cosmos DB, con cifrado transparente en reposo y acceso restringido a la API y los servicios internos. Las métricas y los registros de actividad se recogen en Azure Monitor, Azure Application Insights y Azure Log Analytics.

La orquestación combina Azure Functions para tareas dirigidas por eventos (por ejemplo, reindexar en Azure AI Search al subir un documento a Azure Blob Storage) y Azure Kubernetes Service para los servicios web persistentes. La API de respuesta se implementa con Azure App Service o Azure Kubernetes Service y se expone con Azure API Management, que centraliza las peticiones y aplica autenticación, cuotas y logging. La voz en vivo se gestiona con Azure Speech Service. En fases avanzadas se valora Agentic Retrieval para descomponer consultas en subconsultas y devolver respuestas con citas a las fuentes.

4. Integración multicanal

La API de respuesta actúa como cerebro omnicanal: cualquier canal o aplicación interna le envía una pregunta en texto y recibe la respuesta sugerida en texto y, opcionalmente, en voz. La API es de uso interno; solo los agentes y sistemas autorizados la invocan, nunca el público directamente.

En llamadas telefónicas, el agente pulsa un botón de su consola, el audio se transcribe con Azure Speech Service (STT) y la respuesta vuelve en segundos, mostrada en texto y reproducible por voz (TTS). En chat web, la consola actúa como copiloto del agente; opcionalmente, Azure Bot Service y Azure Communication Services conectan el chat del ciudadano con sugerencias en tiempo real. En Email y Formulario Web, el agente envía la consulta a la herramienta y obtiene un borrador de respuesta, con posible integración mediante un complemento de Outlook. La presencia de la IA es transparente para el ciudadano.

5. Consola del agente y portal de administración

La consola del agente es una aplicación web responsive desarrollada con React o Angular, alojada en Azure App Service y autenticada con Azure Active Directory. Permite introducir consultas por texto o por micrófono, muestra la respuesta sugerida (con opción de escucharla por voz), guarda cada pregunta, respuesta y tiempo, y deja al agente calificar la utilidad de la sugerencia en una escala. La consola mantiene el historial de la sesión, permite copiar la respuesta y ofrece una búsqueda manual en la base de conocimiento sobre el mismo índice de Azure AI Search. Está diseñada para convivir con el CRM, integrándose como ventana flotante, iframe o plugin.

El portal de administración, accesible solo a roles autorizados, permite gestionar contenidos (subir, modificar o retirar documentos del corpus en Azure Blob Storage y lanzar la indexación), supervisar las sesiones en tiempo real, ajustar parámetros del sistema (umbrales de confianza, credenciales del CRM, usuarios y roles) y consultar métricas básicas. Tanto la consola como el portal usan Azure Active Directory, con roles diferenciados de Agente y Administrador.

6. Cuadro de mando

El cuadro de mando se construye con Power BI sobre las métricas de Azure Application Insights, Azure Monitor y Azure Log Analytics. Responde a preguntas como cuántas consultas asiste la IA, qué porcentaje de sugerencias se marcan como útiles, en qué temáticas el modelo es más fuerte o más débil (tasa de acierto por categoría), el tiempo de respuesta y su latencia, el uso por canal y franja horaria, y la evolución temporal. El informe de Power BI puede incrustarse en el portal de administración para su consulta interna.

7. Seguridad y cumplimiento

La seguridad es transversal y la solución cumple el ENS Nivel Alto desde el diseño. El control de acceso se basa en Azure Active Directory con autenticación multifactor, RBAC y delegación mediante OAuth2/OpenID Connect, siguiendo el principio de mínimo privilegio. Los secretos —claves de API, cadenas de conexión— se guardan en Azure Key Vault con rotación periódica.

Los servicios residen en una Azure Virtual Network aislada, con grupos de seguridad de red (NSG) y firewalls que restringen los orígenes; los servicios internos no son accesibles desde Internet. Los datos personales se cifran en tránsito con TLS 1.2 o superior y en reposo con AES-256. La solución mantiene trazas de auditoría completas de accesos y cambios, que pueden integrarse con el SIEM del organismo. Azure Security Center supervisa la plataforma y genera alertas ante anomalías.

La resiliencia se apoya en el despliegue en la región Azure Europa Oeste (u otra región certificada para el ENS, incluidas las de España), con pods de Azure Kubernetes Service distribuidos en varias zonas de disponibilidad y posibilidad de instancia secundaria en otra región europea. El desarrollo es seguro: el código se analiza con SonarQube, se siguen las guías CCN-STIC y los controles OWASP Top 10, se realiza pentesting (idealmente por un tercero) antes de producción y el código se gestiona en Azure DevOps o GitHub Enterprise. Se cumplen las medidas del Anexo II del ENS: separación de entornos, no uso de datos reales sin anonimizar en pruebas e inventario de dependencias de terceros.

En el plano legal, Entelgy actúa como encargado del tratamiento y cumple GDPR: confidencialidad del personal mediante NDA, notificación inmediata de incidentes, capacidad de eliminar o anonimizar datos al finalizar el contrato y prohibición de subcontratar el tratamiento sin autorización. Microsoft Azure cuenta con certificación ENS Nivel Alto para más de 170 servicios.

8. Trabajos a desarrollar (RF01–RF09)

RF01 — Preparación de la Base de Conocimiento. Entelgy depura, normaliza (UTF-8, extracción de tablas, OCR de imágenes), categoriza por temas y resuelve duplicados y contradicciones del corpus de AcmeInc, con trazabilidad de todos los cambios. Crea taxonomías y ontologías de términos financieros y lo indexa en una base vectorial mediante Azure AI Search con embeddings y metadatos para cita y referencia. Produce el entregable Base de Conocimiento.

RF02 — Arquitectura. Define la arquitectura técnica sobre Azure AI Foundry, evalúa y selecciona el modelo de IA (incluida la opción de modelos open source y de razonamiento), decide el despliegue cloud frente a on-premise y dimensiona la infraestructura con Azure Kubernetes Service, Azure Functions, Azure OpenAI, Azure AI Search, Azure Blob Storage y Azure Speech Service, garantizando compatibilidad con OpenShift y acceso por VPN a los entornos de AcmeInc. Produce el Documento de Arquitectura.

RF03 — Entrenamiento del Modelo. Entrena el modelo en Azure OpenAI con las preguntas históricas de los dos últimos años aportadas por AcmeInc, aplicando Fine-tuning supervisado y, según la complejidad, RFT o DPO, mediante Azure AI Foundry. Produce el Modelo Entrenado.

RF04 — Validación del modelo. Valida el modelo contra un conjunto nuevo de preguntas aportado por AcmeInc y compromete una tasa de acierto mínima del 80%. Produce el Informe de Validación.

RF05 — Implementación del Prototipo. Desarrolla la API de inferencia (sobre Azure App Service y Azure Kubernetes Service, expuesta con Azure API Management) y la consola web para los agentes, con STT y TTS mediante Azure Speech Service. El prototipo acepta entradas de los canales de AcmeInc, registra preguntas, respuestas y tiempos, y permite calificar cada respuesta para alimentar la optimización. Produce el Prototipo.

RF06 — Optimización del sistema. Prueba el sistema con usuarios reales sobre la consola, recoge nuevos conjuntos de preguntas y reentrena el modelo manteniendo la tasa de acierto por encima del 80%. Produce el Informe de Optimización.

RF07 — Integración con el CRM. Integra la solución con el CRM que AcmeInc seleccione durante el ejercicio, mediante Azure Service Bus, Azure Logic Apps y conectores nativos si es Dynamics 365. La integración permite abrir tickets con los datos de contacto estructurados (nombre, NIF, email, teléfono) y adjuntar el historial de la consulta.

RF08 — Cuadro de Mando. Genera los informes de rendimiento con Power BI sobre los datos de Azure Application Insights, Azure Monitor y Azure Log Analytics. Produce el Cuadro de Mando.

RF09 — Actualización. Implementa en la consola los mecanismos para que los administradores incorporen automáticamente nuevos elementos al modelo y retiren documentos del corpus, mediante CI/CD con Azure DevOps que reindexa en Azure AI Search y, si los cambios son mayores, reentrena el modelo validando de nuevo por encima del 80%.

9. Plan de calidad

El plan de calidad se apoya en prácticas DevSecOps y en Integración y Despliegue Continuo (CI/CD), con la infraestructura gestionada como código (IaC) y orientado a la reutilización, la alta cohesión y el bajo acoplamiento. Las pruebas se automatizan dentro de los pipelines con JUnit (unitarias), Selenium (interfaz), SoapUI (servicios web) y JMeter (rendimiento), y se gestionan con Testlink.

SonarQube, integrado en GitLab, controla la calidad y la seguridad del código con un Quality Gate que exige 0 vulnerabilidades críticas, un máximo de 5 mayores, cobertura de tests mínima del 80% y duplicación máxima del 3%, y aplica Quality Profiles basados en OWASP Top 10. Ninguna versión se despliega si no supera los tests y el análisis de calidad. El gobierno del servicio se articula en comités operativo, táctico y estratégico, complementados con un buzón de feedback, dentro del Modelo de Calidad e Integración/Despliegue Continuo (MCID).

10. Planificación y fases del proyecto

El proyecto se organiza en tres fases consecutivas, con hitos de control entre los meses 4 y 20.

La **Fase de Transición** dura 1 semana y sienta las bases de conocimiento, accesos y modelo organizativo. Produce el Plan de Adquisición del Conocimiento, el Modelo de Gobierno, el Plan del Proyecto, el Plan de Riesgos y la ubicación de la información a tratar.

La **Fase de Servicio Gestionado** dura 20 meses, ejecuta los requisitos funcionales y desarrolla de forma continua el Plan de Gestión del Conocimiento, las acciones de formación, el Plan de Gestión del Cambio y el Plan de Calidad y Mejora Continua. Genera los Informes de Seguimiento del Proyecto, la Documentación Actualizada, las Actas de Reuniones, los procesos y procedimientos actualizados, la actualización del Mapa de Recursos y la del Plan de Gestión del Conocimiento.

La **Fase de Devolución** dura 2 semanas (10 jornadas) y transfiere el servicio a AcmeInc o a un proveedor entrante en cuatro etapas: preparación, transferencia del conocimiento, transferencia de funciones y cierre. Incluye dos sesiones de formación grabadas (4 horas sobre el funcionamiento de la herramienta y 2 horas sobre su arquitectura) y produce el Informe de Devolución del Servicio y el Plan de Transferencia.

Entelgy compromete una garantía de 12 meses sobre los productos del contrato y soporte post-devolución hasta 4 meses. Durante la garantía, la primera respuesta a incidencias es de 4 horas laborables, la resolución de incidencias críticas de 8 horas laborables y la de incidencias no críticas de 72 horas.

11. Metodología de gestión

La metodología de gestión es Agile: Scrum para los desarrollos grandes y Kanban para incidencias y evolutivos pequeños, con seguimiento en tableros Kanban y dashboards. Entelgy posee la certificación Agile European Scrum y aplica UXD (User eXperience Design) para la toma de requisitos. El trabajo se organiza en sprints de 1 a 4 semanas que producen un Producto Mínimo Viable (MVP) con sus propias pruebas, definiendo criterios Definition of Ready (DoR) y Definition of Done (DoD) e historias de usuario con criterios de aceptación en formato Gherkin. La documentación se centraliza en una wiki técnica sobre SharePoint, con enfoque "just enough documentation".

Los sprints se organizan por las áreas de conocimiento del servicio: Información General, Fiscalidad, Comisiones, Cuentas Directas del Banco de España, Rentabilidad (Deuda General y Últimas Subastas), Canales de Venta (Banco de España, Bancos y Cajas, y AcmeInc.es / SCVV), Fechas de Subastas, Reinversión, Cotización en el Mercado Secundario, Características de la Emisión y Subastas Competitivas y No Competitivas.

12. Equipo de trabajo

El equipo base lo forman 1 Jefe de Proyecto, 1 Consultor IA, 1 Consultor BI, 3 Analista Programador y 1 Documentalista, todos al 100% de dedicación. Un equipo de soporte extendido aporta, a demanda, Consultores Expertos, Consultor IA, Consultor de Productividad, Consultor UX y un Desarrollador de Cuadros de Mando. La estructura de gobierno incluye un Director de Negocio y el Centro de Excelencia de Entelgy, que aporta un perfil de backup por cada miembro del equipo base. El equipo se ubica en las instalaciones de Entelgy en Madrid.